Analisi comparativa della performance di POS Tagging su registri linguistici differenti: Italiano standard vs. Computer-Mediated Communication

[Elisabetta Pellegrini]

[elisabetta.pellegrini02@universitadipavia.it]

Linguistica Computazionale 2025-2026

Abstract

Il presente elaborato si propone di analizzare un processo fondamentale nell'elaborazione del linguaggio naturale (NLP-Natural Language Processing), chiamato POS tagging, ossia il processo per cui ad ogni token di un testo viene assegnata la sua corretta categoria grammaticale. In particolare, il presente studio confronta le prestazioni del POS Tagger della libreria Spacy su due testi caratterizzati da due registri linguistici opposti: l'italiano standard accademico e la "Computer-Mediated Communication" (CMC), caratterizzata da un registro non standard ed informale. L'analisi si concentrerà sul calcolo dell'accuratezza del POS Tagging automatico confrontato con l'annotazione manuale (Gold Standard). Si ipotizza quindi che la performance di Spacy sia più accurata per il primo testo standard, date le limitazioni dei modelli standard su dati non strutturati.

1. Introduzione

È evidente che l'analisi automatica del linguaggio naturale ha raggiunto nel corso degli anni un livello di accuratezza molto alto. Nonostante ciò, la maggior parte dei modelli computazionali vengono addestrati su corpora "standardizzati". Questo significa che vengono addestrati attraverso l'uso di un italiano standard, spesso più pulito e formale (pensiamo ad esempio a corpora basati sui dati di Wikipedia). Il problema quindi si potrebbe porre nel momento in cui questi strumenti vengono a contatto con altre tipologie di linguaggio. Considerando quindi questa ipotesi di ricerca, è stato condotto un esperimento che possa mettere il risalto le possibili differenze e difficoltà che il modello può riscontrare analizzando due testi completamente diversi l'uno dall'altro.

Prima di passare all'osservazione dell'analisi automatica del modello, entrambi i testi sono stati precedentemente annotati da due annotatori umani, al fine di creare il Gold Standard, elemento che risulta essere essenziale per valutare l'accuratezza del modello stesso. Per l'annotazione manuale è stato utilizzato il tagset fornito dalle "Universal Dependencies"[1], che è lo stesso tagset utilizzato dalla libreria Spacy.

Open class words	Closed class words	Other
ADJ	ADP	PUNCT
ADV	AUX	SYM
INTJ	CCONJ	X
NOUN	DET	
PROPN	NUM	
VERB	PART	
	PRON	
	SCONJ	

[1] Universal POS tags

L'obiettivo di questo studio è quindi quello di quantificare le prestazioni di un Pos Tagger quando messo alla prova su un testo poco strutturato, caratterizzato da un'alta informalità e un uso di abbreviazioni e slang tipico della "Computer-Mediated Communication (CMC), ossia il linguaggio utilizzato tipicamente nei social media e nelle chat. L'esperimento è stato condotto seguendo delle fasi specifiche: la prima fase riguarda la tokenizzazione dei due testi, ossia far sì che fossero divisi nelle loro unità minime di analisi. La seconda fase è stata eseguire l'annotazione manuale (del POS Tagging) e successivamente far si che una seconda annotatrice facesse le annotazioni manuali a sua volta per poi poterle validare attraverso l'Inter Annotator Agreement (IIA). La terza fase consiste nel far generare l'annotazione automatica del POS Tagging a Spacy attraverso l'uso di Python. Ed infine, l'ultimo step è stato quello di valutare tutte le metriche standard di valutazione (Accuracy, Precision, Recall e F1-Score) per poter trarre delle conclusioni statistiche sul lavoro svolto dal modello.

2. Dataset e Materiali

Il dataset della ricerca, come anticipato, è composto da due campioni testuali di registro differente: il primo testo è un estratto accademico e formale che tratta del tema dell'intelligenza artificiale e che è caratterizzato da una sintassi complessa, da un lessico specifico, da una punteggiatura corretta e, in linea generale, da un uso standard del linguaggio. Il secondo testo, invece, rappresenta una conversazione informale tra studenti universitari che parlano di un esame. Contrariamente al primo testo, il secondo mostra tratti tipici delle conversazioni del web, come ad esempio: un uso scorretto della punteggiatura, un uso di abbreviazioni particolari e in generale un linguaggio prettamente gergale e colloquiale.

Si riportano entrambi i testi di seguito:

Testo 1:

"In un'epoca caratterizzata da un rapido sviluppo tecnologico e una crescente consapevolezza dell'importanza dell'inclusività, l'uso dell'intelligenza artificiale (IA) nelle tecnologie assistive per l'accessibilità delle applicazioni web e mobile rappresenta un punto di svolta fondamentale. Questa prefazione si propone di introdurre il lettore al tema affascinante e cruciale dell'integrazione dell'IA nel campo delle tecnologie assistive, esplorando il suo impatto, le sfide e le prospettive future.[2]"

Testo 2:

"Il problema dell'esame è Giannetti che l'anno scorso bocciò tantissime persone xkè si fissa con la parte matematica , chiede sempre la definizione di gradiente , divergenza e altre cose sempre di matematica sulle quali luchini e pralits nn insistevano mai sapendo ke nn siamo ferratissimi (nn avendo fatto nemmeno mate).[3]"

L'esperimento è stato condotto su Google Colab utilizzando il linguaggio Python. Inoltre, è stata utilizzata la libreria "Spacy" ed è stato impiegato in particolare il suo modello "it_core_news_md". Il dataset include anche il cosiddetto "Gold Standard", creato attraverso l'analisi delle due annotazioni manuali, per entrambi i testi, eseguite da due annotatori differenti. Per valutare il livello di accordo tra i due annotatori è stato necessario calcolare l'IAA (Inter Annotator Agreement). Il processo consiste

[2] Intelligenza_Artificiale_e_Accessibilita.pdf

[3] Sketch Engine- Corpus: ItTenTen20. Document number: 5779. (2019)

essenzialmente nel far annotare manualmente i testi da due annotatori indipendenti, senza avere la possibilità di consultarsi, per poi confrontarle per validare la qualità dei dati ed evitare incertezze ed ambiguità.

3. Risultati

In questa sezione verranno presentate prima di tutto le varie fasi dell'esperimento e, in seguito, i risultati emersi da quest'ultimo. In primo luogo, la libreria Spacy è stata installata e importata in Google Colab e successivamente è stato caricato il modello pre-addestrato "it_core_news_md" per abilitare l'elaborazione dei due testi mediante la pipeline di Spacy. Dopodiché, è stato possibile convertire entrambi i testi in oggetti doc, ossia la rappresentazione testuale elaborata della pipeline di Spacy. Grazie all'attributo di tokenizzazione (token.text) è stato possibile far eseguire al modello il primo passo, ossia dividere il testo in token e con il secondo attributo di analisi morfosintattica (token.pos-) è stato invece possibile far attribuire al modello l'etichetta adeguata ad ogni token. Dopo aver eseguito quindi la tokenizzazione e il POS Tagging con Spacy per il primo testo, gli stessi procedimenti sono stati seguiti per il secondo.

Per quanto riguarda i passaggi successivi dell'esperimento, è stato fondamentale, come già anticipato precedentemente, calcolare l'accordo tra i due annotatori umani utilizzando la statistica Kappa di Cohen. La Kappa non tiene conto esclusivamente della semplice percentuale di accordo tra i due annotatori, ma tiene anche in considerazione la possibilità che possano concordare per puro caso.

Secondo le linee standard (Landis e Koch)[4] è ritenuto "perfetto" un valore della Kappa che superi "0.80" e, considerando i risultati ottenuti (0.95 per il primo testo e 0.96 per il secondo), è possibile dichiarare che le etichette che sono state inserite manualmente possono essere considerate robuste e soprattutto affidabili.

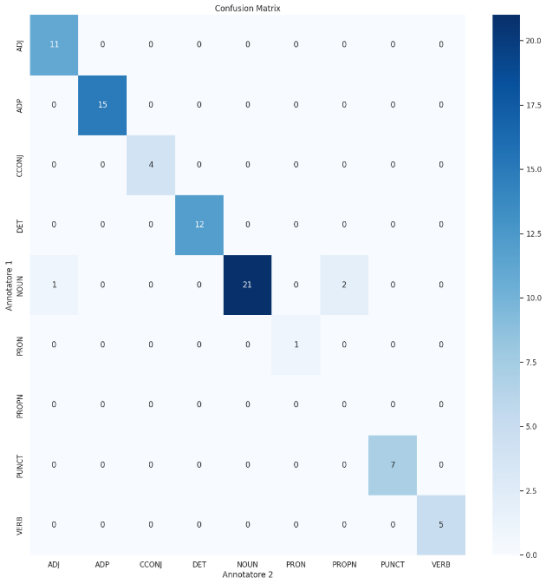


Figura 1: Cohen's kappa 0.95 (Testo 1)

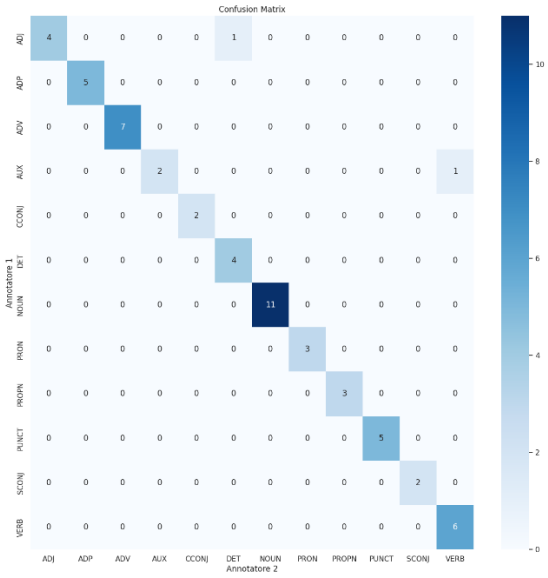


Figura 2: Cohen's kappa 0.96 (Testo 2)

In merito ai risultati ottenuti dal confronto tra l'annotazione manuale e quella automatica, è stato fondamentale utilizzare le metriche di valutazione, ossia: precision, recall, f-1 score e support. Al fine di garantire una lettura

[4] Kappa_K_values.pdf

corretta dei risultati ottenuti, sono state selezionate due metriche di valutazione principali: l'accuratezza (Accuracy) e la media pesata dell'F1-Score (Weighted Avg F1-Score), le quali mostrano un valore totale che tiene in considerazione di tutti i valori riportati per ogni categoria grammaticale ed offrono una sintesi globale della performance del modello. In particolare, la rilevanza della Weighted F1-Score offre una metrica più robusta in presenza di classi grammaticali con frequenze molto diverse tra loro (dataset sbilanciati). Dall'analisi dell'accuratezza emergono risultati eccellenti per il primo testo, confermando quindi l'ipotesi inziale per cui il modello sia più efficace su domini linguistici standard della lingua italiana. I risultati seguenti mostrano infatti dei punteggi quasi perfetti per diverse categorie grammaticali e ciò dimostra che il modello commette raramente degli errori nel momento in cui si trova davanti ad una sintassi corretta. Quanto al secondo testo, è evidente come la percentuale di entrambi i valori sia calata, evidenziando maggiormente le difficoltà che il modello riscontra di fronte ad un linguaggio che si distanzia da un uso tipicamente standard a cui il modello è più abituato, aumentando di conseguenza la complessità nel processo di assegnazione automatica delle categorie grammaticali.
A seguito sono presentate delle tabelle che mostrano i dati recentemente discussi:

Tabella 1: Numero Tokens ed Errori

	N.Tokens	N.Errori
Testo1	79	2
Testo2	52	9

Tabella 2: Valori di Accuracy e Weighted F1-Score

	Accuracy	Weighted F1-Score
Testo1	97.47%	98.68%
Testo2	83.93%	83.29%

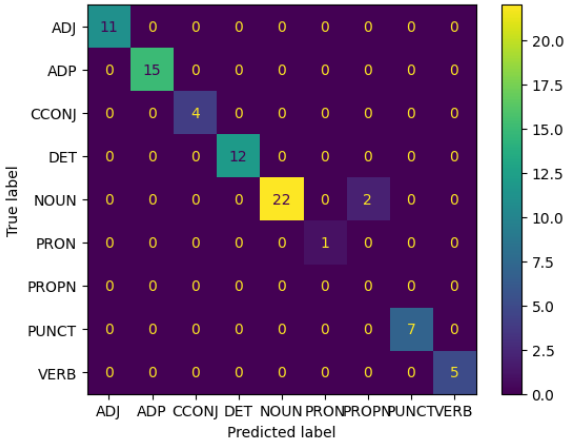


Figura 3: Tabella Metriche di Valutazione(Testo1)

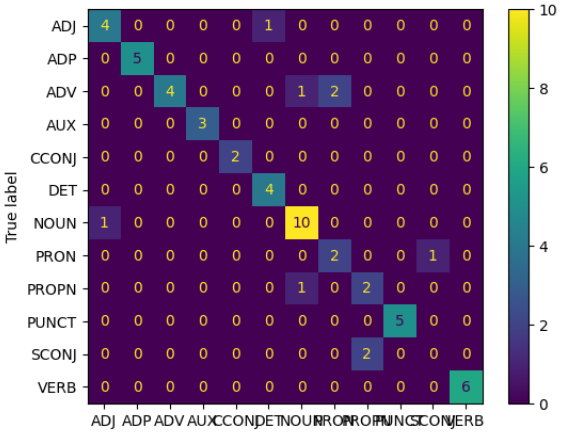


Figura 4: Tabella Metriche di Valutazione(Testo2)

Nel paragrafo 4 verranno analizzati alcuni esempi particolarmente significativi che rappresentano le principali criticità e difficoltà, in particolare del secondo testo, dell'analisi automatica condotta da Spacy.

4. Discussione

4.1 Primo caso di discussione:

L'analisi dei dati ha evidenziato diversi casi di degrado delle prestazioni del modello, che si sono discostate in modo particolare nel caso d'analisi del secondo testo. A tal proposito, la prima problematica riscontrata dal modello automatico potrebbe essere definito il problema "Out-of-Vocabulary". Ciò che è stato constatato è che le diverse forme abbreviate che erano presenti nel secondo testo, ossia "xkè"(perché),

“ke”(che) e “nn”(non), rappresentano dei token sconosciuti per il modello, che essendo stato addestrato su un italiano standard, ha classificato spesso con “PROPN”(nome proprio), oppure nel caso di “nn” con “PRON”.

4.2 Secondo caso di discussione:

Rimanendo all’analisi del secondo testo, è stato notato anche come la classe degli avverbi (ADV) abbia ricevuto una recall abbastanza bassa. Ciò è dovuto al fatto che il modello ha avuto alcune difficoltà a riconoscere gli avverbi all’interno di un testo che è legato sicuramente all’assenza di una punteggiatura e ad una sintassi particolarmente frammentata. Difatti, il modello ha faticato a stabilire le varie dipendenze sintattiche poiché avverbi come “nn” (non), nel momento in cui vengono inseriti in un flusso continuo primo di punteggiatura, creano un livello di ambiguità particolarmente alto per il modello, il quale li ha di conseguenza etichettati rispettivamente come “PRON” e “NOUN”.

4.3 Terzo caso di discussione:

Un terzo caso degno di discussione è stato il mancato riconoscimento da parte del modello dei nomi propri in mancanza della lettera maiuscola a inizio parola. Nel primo testo, ad esempio, notiamo che l’unico errore commesso dal modello è stato definire come “PROPN” l’abbreviazione di intelligenza artificiale “IA”, quando nell’annotazione manuale è stato inserito come “NOUN”. Nel secondo testo, invece, è stato riscontrato il caso contrario, ossia che l’assenza della lettera maiuscola nel cognome di un professore (luchini), ha impedito al modello di riconoscerlo come PROPN e l’ha etichettato come “NOUN”. Ciò suggerisce che il modello fornisce troppa importanza alla maiuscola come caratteristica rilevante ed essenziale nel riconoscimento e assegnazione dell’etichetta “PROPN”.

5. Conclusione

In sintesi, lo studio evidenzia che Spacy presenta significative criticità nell’elaborazione di testi che presentano un linguaggio non standard. I risultati confermano quindi l’ipotesi iniziale per cui il modello avrebbe avuto molte più difficoltà ad etichettare i token del secondo testo, rispetto a quelle riscontrate nel primo. È risultato quindi evidente, sia in termini di Accuracy e Weighted F1-Score (Paragrafo 3), sia attraverso l’analisi quantitativa e la discussione degli errori più eclatanti (Paragrafo 4), che un addestramento “standard” non è sufficiente a gestire delle forme ormai sempre più utilizzate nella CMC e sui social media.

6. Riferimenti Bibliografici

1) Anthony J. Viera, MD; Joanne M. Garrett, PhD. (2005). Understanding Interobserver Agreement: The Kappa Statistic. Kappa_K_values.pdf

2) C.D Manning, “Part of speech tagging from 97% to 100%: Is It Time For Some Linguistics?” in International Conference on Intelligent Test Processing and Computational Linguistics 2011, CICLing, Tokyo, Japan.

3) Jezek, E., Sprugnoli, R. (2023). Linguistica computazionale. Introduzione all’analisi automatica dei testi. Il Mulino. Bologna.

4) Jurafsky, D., Martin, J. H. (2023). Speech and Language Processing: An introduction to speech recognition, computational linguistics and natural.

5) Ortu, M. Intelligenza artificiale e accessibilità. (2024).Intelligenza_Artificiale_e_Accessibilita.pdf

6) Sketch Engine- Corpus: ItTenTen20. Document number: 5779. (2019)

7) spaCy · Industrial-strength Natural Language Processing in Python

8) Universal POS tags